sensors

DOI: 10.3390/s21216948

Sensors (MDPI) Open Access | المجلد 21، العدد 21، المقال 6948

ورقة بحثية أصلية (ORIGINAL ARTICLE) — الترجمة الكاملة الحرفية غير المختصرة لجميع الأقسام والفقرات (17 صفحة)

تصميم قفاز بيانات لتقييم أداء اليد باستخدام التعلم الآلي المشرف

Design of a Data Glove for Assessment of Hand Performance Using Supervised Machine Learning

حسين ثروت[1,*]، حسن ثروت[2]، شادي ع. ماجد[1]، تامر ح. عمارة[3]، أحمد م. البوكل[3]، و محمد إبراهيم عوض[1,*]

[1] قسم هندسة الميكاترونيات، كلية الهندسة، جامعة عين شمس، القاهرة 11517، مصر.

[2] كلية علوم الحاسب والمعلومات، جامعة عين شمس، القاهرة 11566، مصر.

[3] كلية الطب، جامعة عين شمس، القاهرة 11591، مصر.

مقال تصميم قفاز بيانات لتقييم أداء اليد باستخدام التعلم الآلي الخاضع للإشراف

حسين ثروت 1* ، حسن ثروت 2، شادي عبد الله ماجد 1، تامر حسن عمارة 3، أحمد محمد البوكل 3

ومحمد ابراهيم عوض 1*

1 قسم هندسة الميكاترونكس، كلية الهندسة، جامعة عين شمس، القاهرة 11517، مصر؛ Shady.Maged@eng.asu.edu.eg 2 كلية علوم الحاسب، جامعة عين شمس، القاهرة 11566، مصر؛ hassan.mahmoud@cis.asu.edu.eg 3 كلية الطب، جامعة عين شمس، القاهرة 11591، مصر؛ Tamer_emara@med.asu.edu.eg (A.M.E.); ahmed.elbokl@med.asu.edu.eg (T.H.E.); * المراسلات: (HS) 15p8130@eng.asu.edu.eg؛ mohammed.awad@eng.asu.edu.eg (M.I.A.)

ملخص: يشكل العدد الكبير من مرضى الشفاء بعد السكتة الدماغية عبئًا على مراكز إعادة التأهيل والمستشفيات وأخصائيي العلاج الطبيعي. إن ظهور روبوتات إعادة التأهيل وأنظمة التقييم الآلي يمكن أن يخفف هذا العبء من خلال المساعدة في إعادة تأهيل المرضى الذين يتمتعون بمستوى عالٍ من التعافي. وستمكن هذه المساعدة المهنيين الطبيين إما من تقديم خدمات أفضل للمرضى الذين يعانون من إصابات خطيرة أو علاج المزيد من المرضى. كما أنه يترجم إلى مساعدة مالية أيضًا على المدى الطويل. أظهرت هذه الورقة نظام تقييم آلي لإعادة التأهيل في المنزل باستخدام قفاز البيانات، وتطبيق الهاتف المحمول، وخوارزميات التعلم الآلي. يمكن استخدام النظام من قبل مرضى ما بعد السكتة الدماغية الذين يتمتعون بمستوى عالٍ من التعافي لتقييم أدائهم. علاوة على ذلك، يمكن إرسال هذا التقييم إلى أخصائي طبي للإشراف عليه. بالإضافة إلى ذلك، تم إجراء مقارنة بين مصنفين للتعلم الآلي في تقييمهما للتمارين البدنية. يتمتع النظام المقترح بدقة تبلغ 85% (±5.1%) مع اختيار دقيق للميزات والمصنفات.

الاقتباس: ثروت، هـ؛ ثروات، ج.؛

ماجد، س.أ. عمارة، TA؛ البوقل،

أكون.؛ عوض، م. تصميم البيانات

الكلمات الرئيسية: قفاز البيانات؛ إعادة التأهيل المنزلي؛ التعلم الآلي؛ إنترنت الأشياء

قفاز لتقييم اليد

الأداء باستخدام الإشراف

التعلم الآلي. حساسات 2021، 21،

/https://doi.org/10.3390 .6948

1. مقدمة

1. Introduction

s21216948

السكتة الدماغية هي السبب الثاني للوفاة في جميع أنحاء العالم والسبب الثالث للإعاقة [1،2]. ويحدث ذلك عندما يتم إعاقة أو انخفاض تدفق الدم إلى جزء ما من الدماغ، مما يمنع أنسجة المخ من الحصول على الأكسجين والمواد المغذية، وفي غضون دقائق قليلة، تبدأ خلايا الدماغ في الموت. يجب اتخاذ إجراءات فورية لمنع الإصابات أو الوفاة [3].

المحرر الأكاديمي: ماركو إيوسا

تم الاستلام: 15 سبتمبر 2021

تم القبول: 12 أكتوبر 2021

يمكن أن تكون إصابات ما بعد السكتة الدماغية إعاقة قصيرة أو دائمة. يتضمن ذلك فقدان حركة العضلات، وصعوبة التحدث أو البلع، والمشاكل العاطفية، والتدهور المعرفي، و/أو فقدان الذاكرة. تؤثر هذه الإصابات بشكل لا يصدق على الحياة اليومية للناجين من السكتات الدماغية، وبينما يستعيد البعض معظم قدراتهم، يحتاج البعض الآخر إلى اهتمام دائم [3]. علاوة على ذلك، يمكن أن يؤدي فقدان القدرة إلى اكتئاب ما بعد السكتة الدماغية، والذي يؤثر على ما يقرب من ثلث الناجين من السكتات الدماغية [4].

تم النشر: 20 أكتوبر 2021

ملاحظة الناشر: يظل MDPI محايدًا

فيما يتعلق بالدعاوى القضائية في

الخرائط المنشورة والملحقات المؤسسية

.ions

تبدأ عملية إعادة التأهيل بعد السكتة الدماغية عندما تستقر الحالة الطبية للمريض ولا يوجد خطر الإصابة بسكتة دماغية أخرى في

المستقبل القريب. اعتمادًا على شدة السكتة الدماغية، يتعافى بعض المرضى بسرعة؛ ويحتاج آخرون إلى أشهر أو سنوات بعد الإصابة بالسكتة الدماغية. تبدأ الدورة في معظمها في المستشفى ومن ثم يجب أن تكون ممكنة إما في وحدة إعادة التأهيل أو منشأة التمريض الماهرة أو حتى منزل المريض. ويتضمن تمارين بدنية ومعرفية، والتي تحتاج إلى دعم الأطباء وأخصائيي العلاج الطبيعي وممرضات إعادة التأهيل، والمزيد من الاعتماد على حالة المريض. وهي دورة متكررة تشمل: التقييم، وتحديد الأهداف، والتدخل، وأخيرًا، إعادة التقييم [5].

حقوق الطبع والنشر: © 2021 من قبل المؤلفين.

المرخص له MDPI، بازل، سويسرا.

هذه المقالة هي مقالة الوصول المفتوح

موزعة بموجب الشروط و

شروط المشاع الإبداعي

تحتاج العديد من جوانب الأداء الجسدي والعقلي للمريض إلى تقييم متكرر خلال فترة إعادة التأهيل. تشمل تقنيات التقييم الشائعة Fugl- Meyer [6] لتقييم الوظائف الحركية، وحبسة بوسطن التشخيصية

ترخيص الإسناد (CC BY) (https://

/Creativecommons.org/licenses/by

/4.0).

الفحص [7] لتقييم الكلام واللغة، وغيرها الكثير لتقييم مجموعة واسعة من الوظائف. أحد العيوب الشائعة بين هذه الطرق هو الحاجة إلى وجود طبيب لإجراء الاختبار. سلط انتشار فيروس كورونا (COVID-19) الضوء على الحاجة إلى أنظمة إعادة التأهيل والتقييم الآلية في المنزل [8].

يمكن استخدام أنظمة التقييم الآلية لتقليل عدد الزيارات للطبيب للتقييم. تقوم هذه الأنظمة إما بتحليل البيانات [9] أو استخدام مصنف التعلم الآلي [10]. لقد كان استخدام التعلم الآلي في تشخيص المريض وتقييمه في ازدياد [11]. ومع ذلك، لا يمكن أن يحل محل تشخيص الطبيب المدرب [12] ويتم استخدامه عندما لا يكون الطبيب متاحًا. تحتاج الخوارزميات المستخدمة إلى إظهار نتائج موثوقة عند تشخيص ومعالجة البيانات الغائبة والمزعجة. بالإضافة إلى ذلك، يجب أن تكون النتائج واضحة للطبيب. يُنظر إلى العديد من نماذج التعلم الآلي المتقدمة على أنها "صناديق سوداء" نظرًا لأن تعقيدها يحجبها عن التفكير البشري. ولذلك، يتردد الأطباء في التعرف عليها لأنه من الصعب ربط النماذج بدعم الفرضيات. قبل اختبارها على المرضى، يجب أن تتم الموافقة على هذه النماذج من قبل الخبراء السريريين [13].

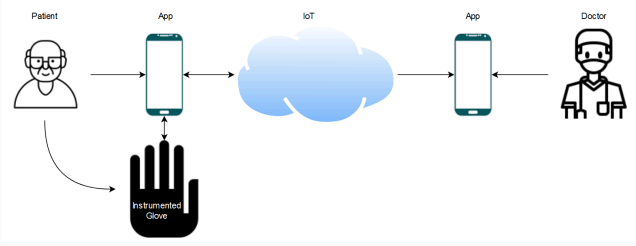
إن إعادة التأهيل من إصابة بالسكتة الدماغية هو مسعى مرهق ماليًا وجسديًا، وقد لا يستطيع الجميع التعامل معه دون القدر المطلوب من الدعم. ومن ثم، هناك حاجة إلى ظهور روبوتات إعادة التأهيل، لأنها تزيد من عدد المرضى الذين يمكن لأخصائيي العلاج الطبيعي علاجهم في وقت واحد، وبتكلفة أقل عادةً [14]. بالإضافة إلى ذلك، يمكن بعد ذلك دمج إنترنت الأشياء (IoT) مع روبوتات إعادة التأهيل لمراقبة المرضى من منازلهم، حتى تقوم أسرهم بتحفيزهم [15].

ستحتاج روبوتات إعادة التأهيل وأنظمة إنترنت الأشياء إلى نظام تقييم آلي يمكنه تتبع تقدم المرضى وتشجيعهم على الأداء بشكل أفضل. تم تضمين أحد الأمثلة على نظام التقييم الآلي في [16]، حيث تم دمج مصنف التعلم الآلي، AdaBoost [17]، مع أجهزة استشعار يمكن ارتداؤها لإنشاء تقييم لإعادة تأهيل الطرف العلوي يعتمد على إنترنت الأشياء. تم تنفيذ أربعة إجراءات مشتركة شائعة الاستخدام يتم إجراؤها بشكل عام في التقييمات السريرية وتم تصنيفها اعتمادًا على نطاق حركة الموضوع. باستخدام الخوارزمية المقترحة، كان متوسط دقة المصنف أعلى من 98%

تم تقديم مثال آخر لنظام التقييم الآلي لإعادة تأهيل الطرف العلوي في [18]، والذي يستخدم بيانات التقاط الحركة باستخدام Microsoft Kinect VS [19]. يتم تتبع حركة 25 مفصلًا للمريض ثم يتم وضعها في نموذج تقييم قائم على شبكة التغذية العصبية (FFNN) لحساب النتائج السريرية. يتمتع النموذج المقترح بدقة إجمالية تتراوح بين 0.87-0.96 اعتمادًا على المهمة المنجزة. تم تقديم أمثلة أخرى للأنظمة الآلية في [20-22].

تم تسليط الضوء على الحاجة إلى التقييم الآلي وإعادة التأهيل في الدراسات الحديثة [23-25]. توفر أنظمة التقييم الآلي العديد من الفوائد للمريض والطبيب على حد سواء، ومن المتوقع أن تصبح أداة تكميلية للاستخدام السريري. ومن ثم، تم تشجيع استخدام أساليب التقييم التقليدية في أنظمة التقييم الآلية، لأنها لا تزال تعتبر "المعيار الذهبي" للتحقق من فعالية العلاج.

توضح هذه الورقة تصميم قفاز البيانات مع تطبيق الهاتف المحمول، وقاعدة بيانات في الوقت الحقيقي لتحميل واسترجاع بيانات المريض، وخادم ويب لتقييم أداء المريض. تم جمع بيانات المريض باستخدام قفاز البيانات، الذي تم تجهيزه بأجهزة استشعار مرنة، وأجهزة استشعار مقاومة القوة (FSRs)، ووحدات IMU. يعد هذا أمرًا شائعًا في روبوتات إعادة التأهيل حيث يمكنها جمع العديد من البيانات الحركية ويمكن إقرانها بأطر عمل أخرى. علاوة على ذلك، تم تقييم أداء خوارزميتين للتعلم الآلي لإعادة التأهيل في المنزل. يتم عرض ملخص للعملية الشاملة في الشكل 1. وكان الهدف هو تحديد إمكانية تطبيق تقييم إعادة التأهيل في المنزل من قفاز البيانات والتعلم الآلي. استخدمت جميع الخوارزميات نفس مجموعة الميزات المستخرجة بواسطة قفاز البيانات. هذا استمرار لعملنا السابق في إعادة تأهيل المنزل وتقييمه [26،27].



الشكل 1: الشكل 1. نظرة عامة على النظام.

Figure 1. System overview.

الخطوط العريضة لهذه الورقة هي على النحو التالي. ويوضح القسم التالي تصميم القفازات وتكامل النظام، على التوالي. بعد ذلك، يتم تقديم وصف نظري موجز لخوارزميات التعلم الآلي المستخدمة قبل

وصف البروتوكولات التجريبية المستخدمة. ثم يتم عرض النتائج في القسم 3 ومناقشتها في القسم الأخير.

2. المواد والأساليب

2. Materials and Methods

يشتمل النظام على قفاز البيانات لجمع بيانات المريض، وتطبيق جوال لمراجعة البيانات السابقة وإجراء تقييمات جديدة لمراقبة تقدم المريض، وخادم ويب لحساب تقييم المريض وإعادة نتيجة المريض إلى التطبيق، وقاعدة بيانات عبر الإنترنت لتخزين سجلات المريض.

تبدأ العملية ببدء المريض للتمارين من خلال تطبيق الهاتف المحمول. يرسل التطبيق معلومات التمرين إلى وحدة التحكم الدقيقة Arduino، عبر البلوتوث، ويخبر المريض ببدء التمرين. بناءً على المعلومات المستلمة، يقوم المتحكم الدقيق بقراءة البيانات من أجهزة الاستشعار المحددة ومعالجتها.

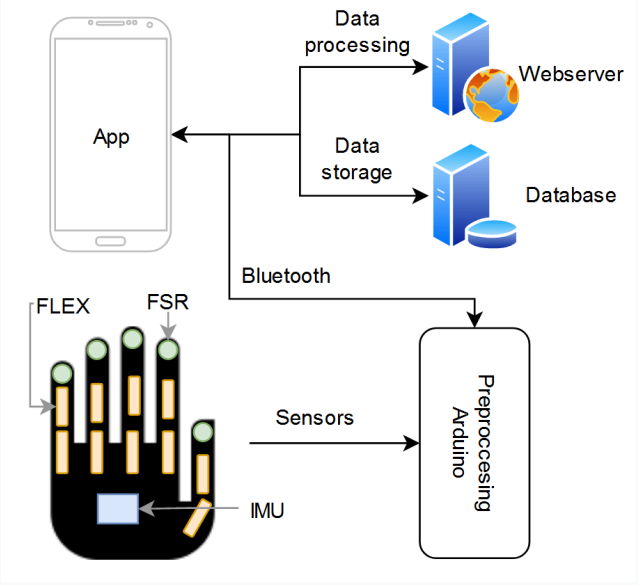
بعد المعالجة، يتم إرسال البيانات مرة أخرى إلى التطبيق. يقوم التطبيق بتحميل هذه البيانات إلى خادم الويب، حيث تتم معالجتها وتقييمها باستخدام خوارزميات التعلم الآلي. يتم بعد ذلك إرسال المخرجات مرة أخرى إلى التطبيق، حيث يمكن تحميلها وتخزينها في قاعدة البيانات لمشاهدتها لاحقًا. يمكن أيضًا الوصول إلى المعلومات الموجودة في قاعدة البيانات بواسطة أخصائي طبي من خلال التطبيق لمراقبة أداء المريض. وتظهر العملية الشاملة في الشكل 2.

2.2. قفاز البيانات

2.2. Data Glove

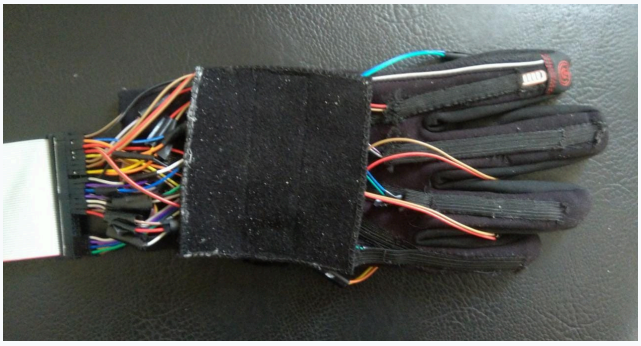
بالنسبة لقفاز البيانات، وضعنا 10 أجهزة استشعار مرنة لتحديد زوايا كل مفصل إصبع، و5 أجهزة استشعار لمقاومة القوة (FSR) لقوة الإمساك، ووحدة IMU ذات 6 محاور للعثور على حركة المعصم. تم تكوين موضع المستشعرات، الموضح في الشكل 2، وفقًا لأدبيات مماثلة حول التعرف على إيماءات اليد [28-31]. تم إثبات دقة قفازات البيانات المماثلة مع خوارزميات التعلم الآلي في العديد من الأوراق البحثية [28,29]. لكن الجانب السلبي الأكبر هو عدم الدقة الناتج عن اختلاف أحجام اليد.

يتم عرض صورة لقفاز البيانات في الشكل 3، حيث يتم ربط المستشعرات داخل القفاز لتوفير مظهر أكثر جمالية. يتم وضع مستشعرين مرنين وجهاز FSR واحد على كل إصبع. تقيس أجهزة الاستشعار المرنة زاوية الانحناء للمفاصل السلامية السنعية والمفاصل السلامية القريبة، بينما يتم وضع FSRs على أطراف الأصابع. يتم وضع المستشعر المرن F1 على المفصل السنعي السلامي للإبهام، بينما يتم وضع F2 على المفصل بين السلاميات. ويتبع نفس النمط لبقية الأصابع.



الشكل 2: الشكل 2. النظام المتكامل.

Figure 2. Integrated system.



الشكل 3: الشكل 3. قفاز البيانات.

Figure 3. Data glove.

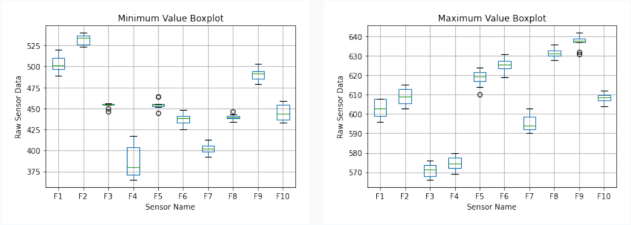
2.3. أجهزة الاستشعار

2.3. Sensors

يتم استخدام مستشعر المرن لتحديد زاوية كل مفصل إصبع [32]. يعمل المستشعر كمقسم للجهد مع مقاومة مسطحة عند الانحناء الطبيعي؛ زيادة الانحناء يزيد من المقاومة. ومع بعض المعايرة، يمكن استخدام هذه القيمة لتحديد زوايا كل مفصل إصبع. لسوء الحظ، يفشل هذا المستشعر في تحديد الاتجاه العام لليد والمعصم، ولهذا السبب تم استخدام مستشعر IMU أيضًا.

لاختبار قابلية تكرار مستشعر المرن، تم تسجيل البيانات الأولية عند موضع البداية وعند أقصى انحراف للأصابع لمدة 10 تجارب. يتم عرض مخطط مربع وشارب لقراءات المستشعر في الشكل 4.

(أ) (ب)



الشكل 4: الشكل 4. مؤامرة مربعة وشاربة لقراءات المستشعر لمعايرة الانحناء. (أ) القيمة الدنيا، تحدث أثناء الانحناء الأقصى، (ب) القيمة القصوى، تحدث أثناء الوضع الأولي.

Figure 4. Box and whisker plot of sensor readings for the calibration of the bending. (a) Minimum Value, occurs during maximum bend, (b) Maximum Value, occurs during initial Pose.

لقياس قوة الإمساك، تم وضع FSR على السلامية البعيدة لكل إصبع [33]. كان FSR أقل دقة بسبب النطاق الصغير للقوى المستخدمة. ولذلك، فإن الحد الأقصى للقراءة التي يصل إليها المريض يمكن أن يعطي نظرة ثاقبة لقوة إمساكه، حيث يقدم الشخص العادي قراءات تبلغ 700 وما فوق. لم تكن هناك حاجة إلى معايرة لهذا المستشعر، وتم أخذ البيانات الأولية فقط لاستخراج الميزات.

يستخدم مستشعر IMU (MPU6050) مقياس تسارع ثلاثي المحاور وجيروسكوب ثلاثي المحاور لتحديد الاتجاه [34]. تم وضع مستشعر IMU على الجزء الخلفي من اليد لتحديد اتجاه المعصم، وهو أمر بالغ الأهمية لتحديد وضع المعصم الحالي. تم تنفيذ التصفية المتوسطة لتسهيل البيانات من IMU [35].

2.4. متحكم

2.4. Microcontroller

تم استخدام Arduino Mega كوحدة تحكم دقيقة بسبب وفرة المدخلات والمخرجات اللازمة لتشغيل القفاز ونقل البيانات. بالإضافة إلى ذلك، نظرًا لأن التعلم الآلي والتصنيف تم إجراؤه باستخدام خادم ويب خارجي، كانت القوة الحاسوبية لـ Arduino كافية للتعامل مع جميع المهام المطلوبة. وتضمنت هذه المهام قراءة البيانات من المستشعر، ومعايرة البيانات لتقليل الأخطاء، واستخراج الميزات، واستقبال البيانات وإرسالها إلى تطبيق الهاتف المحمول باستخدام الاتصال التسلسلي عبر Bluetooth.

2.5. استخراج الميزة

2.5. Feature Extraction

يتم عرض القراءات من كل مستشعر في الجدول 1.

جدول 1: الجدول 1. بيانات الاستشعار.

Table 1. Sensor data.

قراءات الاستشعار

قوة الانحناء المرنة، قوة الإمساك، تسريع وتوجيه IMU

بالنسبة لمستشعر المرن، تم استخدام المتوسط والجذر المتوسط التربيعي (RMS) والانحراف المعياري والقيمة الدنيا. بالنسبة لـ FSR، تم أخذ المتوسط وRMS والانحراف المعياري والقيمة القصوى. أخيرًا، تم استخراج الميزات المستخدمة عادةً في منهجية وإجراءات مماثلة من IMU، نظرًا لتمثيلها الإحصائي لمجموعات البيانات الكبيرة [36]. وتضمنت هذه الميزات: المتوسط وRMS والانحراف المعياري لكل محور من محاور مقياس التسارع والجيروسكوب، بالإضافة إلى منطقة حجم الإشارة (SMA) لمقياس التسارع والجيروسكوب.

وكانت المعادلة المستخدمة لحساب SMA لمقياس التسارع والجيروسكوب هي:

ض المجموع

1 = fSMA إجمالي

0 إس(ر)| + إص(ر)| + إض(ر)|دت (1)

SMA هو التكامل القياسي للقيم الأصلية، ويتم الحصول عليه عن طريق تقسيم المنطقة أسفل المنحنى مع الفاصل الزمني للقراءات [37].

2.6. تطبيق الهاتف المحمول

2.6. Mobile Application

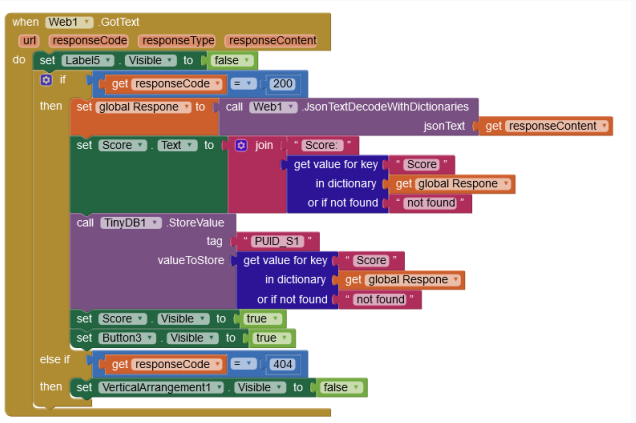
تم تطوير تطبيق الهاتف المحمول، المسمى iGrasp، باستخدام تطبيق MIT App Inventor، وهو أداة لتطوير ترميز الكتل على الويب لهواتف Android [38]. تم تطوير أداة التطوير مفتوحة المصدر هذه بواسطة Google ويتم صيانتها حاليًا بواسطة معهد ماساتشوستس للتكنولوجيا.

كان الغرض من التطبيق هو مراقبة تقدم المريض والتحقق من وجود أي تشوهات، ولهذا تم إضافة الميزات التالية:

▪ يمكن للمرضى عرض درجاتهم من المحاولات السابقة. ▪ يستطيع المرضى الاتصال بقفاز البيانات وتحميل نتائج المحاولات الجديدة. ▪ يمكن للأطباء عرض النتائج التي تم تحميلها لمرضاهم.

عند بدء التطبيق، يقوم المستخدم أولاً بالتسجيل كمريض أو طبيب. التسجيل كطبيب سيسمح له باسترداد بيانات المريض من قاعدة البيانات، في حين أن التسجيل كمريض سيمكنه من تقييم أدائه. يمكن للمستخدم تخزين درجة أدائه لمشاهدتها لاحقًا عن طريق تحميلها إلى قاعدة البيانات، أو إذا وجد النتيجة غير مرضية، فيمكنه إعادة محاولة محاولته عدة مرات حسب الحاجة. أثناء أداء التمارين، يعرض التطبيق صورًا وتعليمات مفيدة لتوجيه المستخدم حول كيفية أداء التمرين.

يتصل تطبيق الهاتف المحمول بقفاز البيانات عبر البلوتوث. يبدأ بروتوكول الاتصال بإرسال تطبيق الهاتف المحمول التمرين الذي يؤديه الشخص حاليًا. تقوم وحدة التحكم الدقيقة بعد ذلك بتسجيل البيانات من أجهزة الاستشعار المطلوبة، واستخراج الميزات، ثم إرسال الميزات المستخرجة إلى التطبيق كملف نصي JSON. يرسل التطبيق ملف JSON إلى خادم الويب للتقييم قبل استرداد النتيجة وعرضها على المريض. يتم عرض كتلة المثال في الشكل 5.



الشكل 5: الشكل 5. في هذه المجموعة، يقرأ التطبيق استجابة الويب ويخزنها في ذاكرة الهاتف، حيث يمكن تحميلها لاحقًا. إن بساطة البرمجة المستندة إلى الكتل تجعلها متاحة للاستخدام والتحرير دون الحاجة إلى فني ماهر.

Figure 5. In this block, the application reads the web response and stores it in the phone's memory, where it can be uploaded later. The simplicity of block-based coding makes it available for use and editing without the need for a skilled technician.

2.7. خادم الويب وقاعدة البيانات

2.7. Web Server and Database

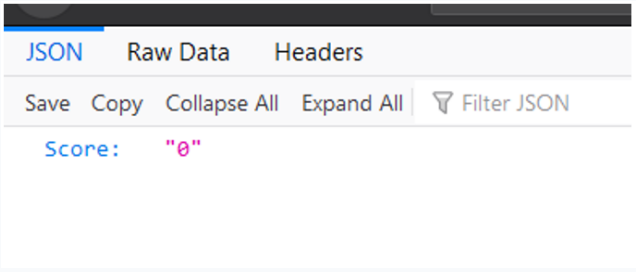
تمت كتابة خادم الويب باستخدام Flask API [39]. إنه تصميم إطار تطبيق ويب لواجهة بوابة خادم الويب (WSGI) خفيف الوزن وقابل للتطوير لتطبيقات الويب البسيطة. كانت وظيفة تطبيق الويب الخاص بنا هي تلقي بيانات المريض من الهاتف المحمول

التطبيق، الذي تلقاه من قفاز البيانات، وتشغيل نموذج التعلم الآلي المستخدم لتعيين درجة للمريض. سيقوم تطبيق الويب بعد ذلك بإخراج ملف JSON الذي يقرأه تطبيق الهاتف المحمول ويعرضه للمريض.

تمت استضافة خادم الويب باستخدام منصة Heruko [40]. تم استخدام هذه المنصة للأسباب التالية:

▪ ويقدم دعم بايثون. ▪ وهو يدعم نموذج التعلم الآلي المستخدم. ▪ لديه خطوات بسيطة لتشغيل ونشر تطبيق الويب. ▪ يمكن الاعتماد عليه ولا يحتاج إلى صيانة أو تحديث مستمر. ▪ أنها قابلة للتطوير وفعالة من حيث التكلفة.

لم يكن لدى خادم الويب واجهة مستخدم مباشرة وكان مخصصًا فقط للتفاعل مع تطبيق الهاتف المحمول. قد تؤدي المحاولات الأخرى لزيارة الموقع إلى حدوث خطأ 404. لن يُخرج تطبيق الويب سوى ملف JSON كما هو معروض في الشكل 6. ويعرض ملف JSON هذا نتيجة المريض للتمرين الذي حاول القيام به.



الشكل 6: الشكل 6. إخراج ملف JSON.

Figure 6. Output JSON file.

2.8. قاعدة البيانات

2.8. Database

بالنسبة لقاعدة البيانات، استخدمنا Firebase [41]. تم تطويرها بواسطة Google، وهي عبارة عن قاعدة بيانات NoSQL تقوم بمزامنة البيانات في الوقت الفعلي مع جميع الأجهزة المتصلة على السحابة. تم تصميم هذه المنصة لتطبيقات الهاتف المحمول والويب وتم استخدامها في هذا العمل نظرًا لميزة قاعدة البيانات في الوقت الفعلي، مما يسمح لنا بتحديث سجلات المرضى وتخزينها في جميع أنحاء العالم.

يمكن لكل مستخدم معاينة سجل محاولاته، بما في ذلك مراقبة تقدمه. تتيح قاعدة البيانات أيضًا لأخصائيي العلاج الطبيعي والأطباء مراقبة مرضاهم، إذا كان لديهم إمكانية الوصول إلى أسماء المستخدمين الخاصة بالمرضى على التطبيق.

2.9. التعلم الآلي

2.9. Machine Learning

كان نظام تعزيز التدرج الأقصى (XGBoost)، وهو نظام تعزيز مفتوح المصدر، أحد الخوارزميات المستخدمة لتقييم المريض [42]. تعزيز التدرج، بشكل عام، هو استراتيجية تجميع حيث تقوم كل شجرة بتعزيز العناصر التي أدت إلى التصنيف الخاطئ للشجرة السابقة، من خلال إعطاء درجة مستمرة لكل ورقة. على سبيل المثال، يتم استخدام قواعد القرار لتصنيف الأوراق وحساب التنبؤ النهائي عن طريق جمع النتيجة في الأوراق المقابلة (المقدمة بواسطة wi).

يمكن أن يكون الهدف المنظم بعد ذلك:

∑ = (φ)ل

∑ + (yi, yi^)ل

أوم (فك) (2)

أين:

Ω(fk) = γT + 1

2 ‖ ث ‖ 2 (3)

يمثل ا دالة خسارة محدبة قابلة للتمييز تقوم بتقييم المسافة بين القيمة المتوقعة yi^ والقيمة المستهدفة Ω(fk) .yi يشير إلى مصطلح التنظيم الذي يساعد في منع الإفراط في التجهيز، حيث يشير fk و T إلى نظام شجرة مستقل و

عدد الأوراق في النظام على التوالي. تم استخدام تقنية تنظيم مماثلة في [43].

تم تدريب النموذج بطريقة تجميعية، وذلك لعدم قدرة الطرق التقليدية على تحسين نموذج المجموعة الشجرية في المعادلة (2)، حيث أنه يتضمن وظائف مثل

حدود. دع ŷ(t)

أشير إلى التنبؤ بالمثيل i في التكرار t. يجب إضافة ft لتقليل الهدف:

ن Σ ط=1

ل(ر) =

ل(ŷ(t−1), ŷ1

أنا + قدم(xi)) + Σ

أوم (قدم) (4)

تم استخدام توسعة تايلور من الدرجة الثانية لتحسين الوظيفة. تمت بعد ذلك إزالة الأجزاء الثابتة، وأصبح الهدف المصغر عند t هو:

ن Σ ط=1

[جي قدم (الحادي عشر) + 1

L˜(ر) =

2hi و 2 ر (xi)] + Ω(قدم) (5)

حيث يشير gi hig إلى إحصائيات التدرج من الدرجة الأولى والثانية في دالة الخسارة، على التوالي. يمكن تقييم القيمة المثلى المقابلة، بعد حساب وزن الورقة j لبنية ثابتة q(x)، باستخدام:

2(i∈lj gi∑)

تي Σ ي=1

L˜(ر) = −1

LA + γT (6) مرحبا i∈lj∑

يمكن استخدام المعادلة (6) لتقييم أداء بنية الشجرة ف. يستخدم XGBoost نسخة معدلة من الخوارزمية الجشعة، تسمى خوارزمية الجشع التقريبية [44]. هذا الإصدار مناسب لمجموعات كبيرة من البيانات لأنه يقلل من عدد الحدود التي يجب مراعاتها، ويختار بدلاً من ذلك فصل البيانات إلى كميات بناءً على توزيع الميزات. تم تحسين هذا بشكل أكبر من خلال استخدام رسم كمي مرجح. يبني الرسم الفرق بين كل كمية على الوزن، وليس على الملاحظة، حيث يكون وزن كل ملاحظة مرتفعًا، مما يعني أن الكميات مقسمة حيث يكون مجموع الأوزان متشابهًا. ولذلك، يتم إنشاء الكميات في المناطق ذات الثقة المنخفضة.

يستخدم XGBoost خوارزمية اكتشاف الانقسام المدرك للتعامل مع البيانات المفقودة. يعمل هذا عن طريق إضافة اتجاه افتراضي في كل عقدة شجرة وتصنيف القيم المفقودة. يتم اختيار الاتجاه الافتراضي بناءً على البيانات السابقة. علاوة على ذلك، فإن الخوارزمية قادرة على معالجة الملاحظات الجديدة ذات القيم المفقودة.

2.9.2. الانحدار اللوجستي

2.9.2. Logistic Regression

يسعى الانحدار اللوجستي [45] إلى تصنيف الملاحظة من خلال تقدير احتمالية وجود الملاحظة في فئة معينة بناءً على قيم المتغيرات المستقلة، والتي يمكن أن تكون مستمرة أم لا.

يتبع المتغير التابع في الانحدار اللوجستي توزيع برنولي الذي له احتمال غير معروف p حيث يتم تصنيف النجاح على أنه 1 والفشل على أنه 0، وبالتالي فإن احتمال النجاح هو p والفشل هو q = 1 − p [46]. في الانحدار اللوجستي، نقدر p لأي مجموعات خطية معينة للمتغيرات المستقلة.

لربط مجموعتنا الخطية من المتغيرات معًا، كنا بحاجة إلى دالة تربطها معًا وتقوم بشكل أساسي بتعيين المجموعة الخطية من المتغيرات التي يمكن أن تؤدي إلى أي متغير على توزيع احتمال برنولي حيث p ∈(0, 1).

اللوغاريتم الطبيعي لنسبة الأرجحية هو الدالة:

احتمالات (7) ln = ln p 1 −p = logit(p)

ومع ذلك، في الدالة اللوغاريتمية لدينا، كان من 0 إلى 1 يمتد على طول المحور السيني، لكننا أردنا أن تكون احتمالاتنا على المحور الصادي؛ يمكننا تحقيق ذلك عن طريق أخذ معكوس الدالة اللوغاريتمية.

logit−1(α) = 1 1 + e−α = eα

1 + ألفا (8)

حيث α تساوي المجموعة الخطية للمتغيرات المستقلة ومعاملاتها. اللوغاريتم الطبيعي لنسبة الأرجحية يعادل دالة خطية للمتغيرات المستقلة. يسمح لنا antilog الخاص بوظيفة logit بإيجاد معادلة الانحدار المقدرة:

logit(p) = ln p 1 −p = β0 + ∑(βi ∗xi) (9)

antilog = p 1 −p = exp(β0 + ∑(βi ∗xi)) (10)

p = exp(β0 + ∑(βi ∗xi)) 1 + exp(β0 + ∑(βi ∗xi)) (11)^

حيث β0 و β1 هما معاملا التحيز والأوزان، على التوالي. من أجل تحديث المعاملات βi، استخدمنا أقصى احتمال:

الاحتمالية = ^ (12) (1 −p)∗ (1 −^p) + p ∗p

ثم قم بتحويل وظيفة الاحتمالية باستخدام تحويل السجل:

سجل (الاحتمالية) = سجل (^ص) ∗ص + سجل(1 −^ص) ∗(1 −ص) (13)

أخيرًا، يمكننا جمع دالة الاحتمالية عبر جميع الأمثلة في مجموعة البيانات لزيادة الاحتمالية إلى الحد الأقصى:

ن Σ ط=1

(سجل (pi^) ∗pi + سجل(1 −pi^) ∗(1˘pi) (14)

فماكس =

من الممارسات الشائعة تقليل دالة التكلفة لمشاكل التحسين؛ لذلك، يمكننا عكس الدالة بحيث نقوم بتقليل احتمالية السجل السلبي:

ن Σ ط=1

فمين = -

(سجل (pi^) *pi + سجل(1 – pi^) *(1˜pi)) (15)

حساب سالب دالة الاحتمالية اللوغاريتمية لتوزيع برنولي يعادل حساب دالة الإنتروبيا المتقاطعة لتوزيع بيرنولي، حيث يمثل ci احتمالية الفئة i وd يمثل تقدير التوزيع الاحتمالي، في هذه الحالة من خلال نموذج الانحدار اللوجستي الخاص بنا.

Fcrossentropy = –∑(log(d) *ci) (16)

2.10. البروتوكولات التجريبية

2.10. Experimental Protocols

أجريت الدراسة وفقًا لإعلان هلسنكي، وتمت الموافقة على البروتوكول من قبل مجلس المراجعة الأخلاقية بالجامعة. أعطت جميع المواد موافقتها المستنيرة لإدراجها قبل مشاركتها في الدراسة.

ولتقييم الأداء، طُلب من المشاركين أداء ثلاث مهام، أوصى بها طبيب إعادة التأهيل. تم استخدام هذه المهام لقياس أداء المريض الجيد والجسيم، بالإضافة إلى أي تشنج قد يعاني منه المريض. وقد استهدف هذا النظام الأشخاص الذين يتمتعون بمستوى عالٍ من التعافي، والذين يمكنهم مواصلة إعادة تأهيلهم في المنزل.

بدأت جميع المهام بنفس الوضعية الأولية لليد، وهي كف مفتوح مع مواجهة المؤخر لوجه المشارك. تم تكرار كل مهمة خمس مرات، دون تضمين التجارب العملية.

وكان هذا العدد مناسباً للتقييم، حسب [47]. استمرت كل تجربة لمدة خمس ثوانٍ، وطُلب من المشاركين إكمال كل مهمة ثم العودة إلى وضع البداية بوتيرة مريحة. تم تسجيل المشاركين من 0 إلى 2 لكل تمرين حسب أدائهم.

كانت المهمة الأولى، وهي الإمساك، تتطلب من المشاركين ثني جميع أصابعهم إلى أقصى حد، قبل العودة إلى الوضعية الأولية. إذا كان الشخص غير قادر على الحركة، فسيتم منح المحاولة درجة 0. وإذا كانت هناك حركة قليلة، ولم يتم ثني جميع الأصابع، أو كان الشخص غير قادر على العودة إلى وضع الراحة، فسيتم تسجيل المحاولة كـ 1. وإذا حقق الشخص الحركة الكاملة وعاد إلى وضع الراحة، فسيتم تسجيل المحاولة على أنها 2. وكان ثني مفاصل الأصابع هو الشيء الوحيد الذي تم قياسه خلال هذا التمرين.

في المهمة الثانية، القرص، طُلب من المشارك أن يقرص أصابعه ويمارس أكبر قدر ممكن من القوة، ثم يجب عليه العودة إلى الوضع الأولي. لم تسفر أي حركة أثناء المحاولة عن 0. تم تسجيل الحركة غير الكاملة أو عدم القدرة على القرص (أي القوة الضعيفة أو عدم ممارسة أي قوة) أو العودة إلى الوضع الأولي كـ 1. أعطت الحركة الكاملة درجة كاملة 2. وشملت قياسات هذا التمرين ثني الإبهام والسبابة، بالإضافة إلى قوة القرص.

المهمة النهائية تنطوي على التلويح. طُلب من المشارك ثني معصمه ثم التلويح بشكل متكرر طوال مدة التمرين. يجب أن يتم تنفيذ الحركة بالسرعة العادية، ولم يعود المشارك إلى وضع الراحة. تم تسجيل كل محاولة اعتمادًا على حركة المشارك. تُمنح صفر في حالة عدم الحركة، وواحدة في حالة الحركة البسيطة أو الجزئية، أو الثني غير الكامل للمعصم، أو الثني الكامل، ولكن بدون التلويح. أخيرًا، يتم منح اثنين إذا أكمل الموضوع الحركة الكاملة طوال المدة. تم قياس اتجاه راحة اليد وانثناء المعصم والتسارع أثناء هذا التمرين. يتم عرض المهام في الشكل 7.

(أ) (ب)



الشكل 7: الشكل 7. بروتوكولات التمرين. (أ) الإمساك، (ب) القرص، (ج) التلويح.

Figure 7. Exercise protocols. (a) Grasping, (b) Pinching, (c) Waving.

2.11. مرضى

2.11. Patients

جميع المرضى الذين تم استخدامهم في هذه الدراسة، والذين تم جمعهم من مركز إعادة التأهيل، عانوا جميعًا من درجات متفاوتة من الضعف في الأطراف العلوية. كان جميع المرضى الثلاثة قادرين على أداء التمرين الأول (الإمساك)، لكن المرضى 1 و3 فقط كانوا قادرين على أداء التمرينين الثاني والثالث. يتم عرض معلومات المرضى في الجدول 2. وكان الطبيب المشرف متاحًا أثناء جمع البيانات وقدم درجة FMA للتدريبات التي تم إجراؤها.

جدول 2: الجدول 2. وصف المريض.

Table 2. Patient description.

رقم الوصف العمر/الجنس

1 77/ذكر مرض السكري غير المنضبط والضعف العام 2 65/ذكر متلازمة العصبون الحركي المشتبه بها 3 91/ذكر مرض باركنسون

3. النتائج

3. Results

تم استخدام مصنفين مختلفين للتعلم الآلي، XGBoost والانحدار اللوجستي، ومقارنتهما لاختبار الخوارزمية الأكثر كفاءة. تم اختيار هذه المصنفات بناءً على رؤيتها، مما يسهل على الأطباء فهم عمليتها، وبالتالي التنبؤ بالمكان الذي قد تحدث فيه الأخطاء. تم تكرار كل خوارزمية خمس مرات لكل تمرين لاختبار مجموعات الميزات المحتملة. تم اختيار مجموعات الميزات لكل مجموعة بشكل عشوائي، حيث تتضمن مجموعة الميزات الأولى جميع الميزات. تم جمع مجموعة البيانات باستخدام أربعة أشخاص يتمتعون بصحة جيدة، ثلاثة ذكور وأنثى واحدة، بمتوسط عمر 36.5 ± 17.8 سنة. طُلب من الأشخاص الأصحاء أداء التمرين بدرجات متفاوتة من النجاح وتم تسجيلهم من 0 إلى 2، وفقًا لتقييم Fugl-Meyer.

بدأ كلا المُصنفين بنفس الحالة العشوائية، وتم أخذ مجموعة الاختبار على أنها 30% من إجمالي مجموعة البيانات. كان لمصنف XGBoost حد أقصى لعمق الشجرة يبلغ 3، ومعدل تعلم 0.7، في حين استخدم مصنف الانحدار اللوجستي الانحدار متعدد الحدود وكان له حد أقصى للتكرار قدره 100. ثم تم اختبار أداء كل مصنف باستخدام التحقق المتبادل بخمسة أضعاف [48].

في التمرين الأول، تم استخدام أجهزة الاستشعار العشرة الموضوعة على مفاصل الأصابع فقط. وكانت هذه الميزات المستخرجة من أجهزة الاستشعار المرنة هي الحد الأدنى، والمتوسط، والانحراف المعياري، والجذر المتوسط للتربيع. يعرض الجدول 3 دقة k-fold لمجموعة ميزات XGBoost (XGB) والانحدار اللوجستي (LR).

جدول 3: الجدول 3. دقة XGB وLR لاستيعاب.

Table 3. XGB and LR accuracy for grasping.

يتميز بتقنية XGBoost LR

الكل 90.00% ± 9.35% 87.50% ± 7.91% وSTD Min 90.00% ± 10.00% 92.50% ± 9.35% المتوسط و85.00% ± 10.00% RMS 82.50% ± 9.35% STD ± 7.91% و87.50% ± 6.12% RMS المتوسط 92.50% والحد الأدنى 85.00% ± 14.58% 90.00% ± 5.00% المتوسط 88.00% ± 9.88% 88.50% ± 8.03%

استخدم التمرين الثاني أجهزة الاستشعار المرنة وFSRs الموضوعة على إصبعي السبابة والإبهام. تم أيضًا استخراج نفس الميزات الخاصة بأجهزة الاستشعار المرنة من أجل FSRs، باستثناء أنه تم استبدال القيمة الدنيا بالقيمة القصوى لـ FSR. يتم عرض النتائج في الجدول 4.

جدول 4: الجدول 4. دقة XGB وLR للقرص.

Table 4. XGB and LR accuracy for pinching.

يتميز بتقنية XGBoost LR

الكل 82.50% ± 10.00% 90.00% ± 9.35% و STD Min 90.00% ± 18.37% 85.00% ± 9.35% المتوسط و 82.50% ± 10.00% RMS 80.00% ± 6.12% STD و ± 7.91% 87.50% ± 9.35% RMS المتوسط 90.00% والحد الأدنى 75.00% ± 0.00% 70.00% ± 12.75% المتوسط 83.50% ± 7.74% 83.00% ± 10.90%

في التمرين الأخير، التلويح، تم استخدام IMU الموضوعة على الضربة الخلفية فقط لتسجيل البيانات. يتم عرض النتائج في الجدول 5.

جدول 5: الجدول 5. دقة XGB وLR للتلويح.

Table 5. XGB and LR accuracy for waving.

يتميز بتقنية XGBoost LR

الكل 90.00% ± 9.35% 90.00% ± 9.35% وSTD SMA 90.00% ± 11.18% 87.50% ± 9.35% المتوسط و87.50% ± 26.69% RMS 77.50% ± 11.18% STD و± 18.37% 85.50% ± 5.00% RMS المتوسط 85.00% ± 12.75% 82.50% ± 23.18% SMA المتوسط 67.50% ± 14.71% 86.50% ± 12.57%

ثم تم اختبار النماذج المنتجة على المرضى الثلاثة، وتمت مقارنة النتائج بدرجة الطبيب. يتم عرض أداء نماذج XGB وLR مقارنة بنتيجة الطبيب في الجدولين 6 و7، على التوالي، مع تحديد مجموعة الميزات الأفضل أداءً (BPF) أيضًا.

جدول 6: الجدول 6. أداء XGBoost.

Table 6. XGBoost performance.

فهم قرصة الموجة

RMS ALL ALL BPFg BPF STD دقة 53% 78% 90% متوسط 33% 78% 80%

جدول 7: الجدول 7. أداء LR.

Table 7. LR performance.

فهم قرصة الموجة

متوسط BPF STD وRMSg RMSg جميع دقة 70% 78% 87% BPF المتوسط 56% 60% 54%

4. المناقشة

4. Discussion

لتقييم أداء المريض، أظهرت النتائج المبينة في القسم السابق الحاجة إلى الاختيار الدقيق للمصنف. يمكننا أن نلاحظ أنه بالنسبة للشخص السليم، تفوق مصنف LR على مصنف XGB بهامش صغير. ومع ذلك، عند إجراء التمارين التي يؤديها المرضى، كان أداء كل مصنف مختلفًا اعتمادًا على التمرين. وبما أن التمارين المختارة تؤثر على اختيار المصنف، فإن الخيار الأول سيكون اختيار المصنف LR بسبب أدائه العام العالي. إن التخلي عن التمرين الثالث، أو استبداله بتمرين مماثل حيث يكون أداء مصنف LR أفضل، هو الخيار الثاني. وأخيرا، يتمثل الخيار الثالث في استخدام كلا المصنفين، على الرغم من التكلفة الحسابية الأعلى.

على الرغم من أن استخدام جميع الميزات غالبًا ما يؤدي إلى أعلى دقة، فمن الممكن أيضًا ضبط ميزاتك بشكل مفرط عن طريق اختبار تأثيرها. على سبيل المثال، في تمرين التلويح، يمكن لمصنف XGB تحقيق نفس المستوى من الدقة باستخدام STD وRMSg فقط مثل استخدامهما جميعًا. يمكن أن يؤدي إجراء المزيد من الاختبارات على كل تمرين إلى اختيار ميزة محددة؛ وهذا يقلل من الوقت الحسابي ويزيد من معدل أخذ العينات [49-51].

ومن المتوقع أن تنخفض دقة المصنفات عند اختبارها على المرضى الذين يعانون من إصابات في الأطراف العلوية. كان هذا بسبب عدم انتظام الحركة وصعوبة التكرار مع الأشخاص الأصحاء للتدريب على مجموعة البيانات. ومع ذلك، عند تحسين أداة التصنيف واختيار الميزات، وصل متوسط دقة النظام إلى 85% (±5.1%). وهذه دقة مقبولة سريريًا مقارنة بالأنظمة الآلية الأخرى.

يقدم الجدول 8 مقارنة بين نظامنا والأنظمة الأخرى للتقييم الآلي للجزء العلوي من الجسم. وشملت المقارنة المعدات المستخدمة، والبيانات التي تم جمعها، وكيفية تقييم المرضى وتصنيفهم. استخدمت جميعها تقريبًا خوارزميات التعلم الآلي للتصنيف. يمكن القول إن التعلم الآلي لم يكن مناسبًا للتصنيف بسبب عدم وجود مجموعات بيانات كبيرة. ولذلك، فإن اختيار التعلم الآلي قابل للتطوير

كان المصنف مهما وهذا يسلط الضوء على فوائد أدوات التصنيف مثل XGBoost، التي تستخدم تصنيفًا شفافًا، والذي يمكن للطبيب تقييمه. وتحققت مراقبة إنترنت الأشياء من إمكانية نقل النتائج إلى الطبيب المشرف، وكان الإعداد هو المكان الذي يمكن فيه تنفيذ هذا النظام. وأخيرا، كانت الدقة هي متوسط دقة جميع التمارين التي تم اختبارها على المرضى.

جدول 8: الجدول 8. مقارنة بالأنظمة الأخرى.

Table 8. Comparison to other systems.

كينيكت، مستشعر الضغط، قفاز البيانات،

قفاز البيانات

الموقع، التوجه، التسارع

البيانات الحركية للجزء العلوي من الجسم،

تسريع اليد،

الجزء العلوي من الجسم

السرعة الزاوية،

قوة

قوة تجتاح

طورت الدراسة في [18] نظامًا آليًا يقوم بتقييم المرضى باستخدام شبكة عصبية مغذية [54]. تم استخدام Kinect V2 نظرًا لنظام الرؤية ثلاثية الأبعاد الذي لا يحتوي على علامات، فضلاً عن موثوقيته في الإعدادات السريرية [55]. أجرى المرضى أربع مهام من اختبار وظيفة الذئب الحركي المبسط (WMFT)، ومقياس القدرة الوظيفية WFMT (FAS). لقد كانوا مقيدين باستخدامهم لـ Kinect V2 فقط، لكنهم جادلوا بأن الراحة كانت أفضل وأن استخدام المستشعرات القابلة للارتداء لم يكن خاليًا من القيود، كما تمت مناقشته أعلاه.

استخدم نظام التقييم الآلي في [21] بيانات الحركة من IMU بالهاتف المحمول والبيانات المرئية من الكاميرا الخلفية لتقليل الانحراف، مما يؤدي إلى معلومات أكثر دقة عن الموقع. ثم تم نقل البيانات لاسلكيًا إلى جهاز كمبيوتر لاستخراج الميزات والتقييم الآلي. تم إجراء التقييم باستخدام نهج شجرة القرار. إن الافتقار إلى المعايرة ووضع المستشعر والتكلفة المنخفضة يجعل من هذه الأداة فعالة. ومع ذلك، لم يكن قادرًا على قياس ثني/تمديد الإصبع وقوة الإمساك.

يتضمن النظام المقترح في [22] استخدام عدة قطع غير مكلفة من المعدات لتبسيط إجراءات تقييم FMA، مما يقلل إجمالي وقت التقييم بنسبة 82%. بالإضافة إلى ذلك، يمكن أن تشمل المعدات المستخدمة بسهولة معظم تمارين تقييم FMA. إنها مجرد مسألة إضافة ميزات جديدة وتدريب مجموعة البيانات. تم تدريب مجموعة البيانات باستخدام آلة دعم المتجهات (SVM) [56]. على الرغم من الدقة المنخفضة في الاختبارات الفردية، إلا أن إجمالي الدرجات التي تم تحقيقها كانت على الأقل في حدود 90٪ من الدقة التي حددها الطبيب. كانت الدقة على الأشخاص الأصحاء أعلى بكثير مقارنة بمرضى السكتة الدماغية، خاصة بالنسبة للتمارين التي حصلت على درجة واحدة، حيث كان من الصعب التنبؤ بنطاق الحركة، في حين كان التنبؤ بدرجات صفر واثنين، غير قادرين على الأداء والإكمال الكامل، على التوالي، أسهل بكثير بسبب الاختلافات الطفيفة.

يتميز قفاز البيانات في [28] بتصميم معياري يعمل على إصلاح بعض القيود المفروضة على أجهزة الاستشعار القابلة للارتداء. يمكن أن يتناسب هذا القفاز مع المرضى ذوي أحجام الأيدي المختلفة إذا تم الحرص على وضع مستشعرات IMU الستة عشر. ويستخدم خوارزمية كواترنيون لاستخراج تسارع اليد والسرعات الزاوية وزوايا المفاصل. ثم ينقل البيانات عبر البلوتوث إلى جهاز كمبيوتر للتقييم. وهو يصنف المرضى الذين يستخدمون مجموعات k-means بناءً على مرحلة برونستروم الخاصة بهم ويكون دقيقًا إلى حد معقول في المرحلتين 4 و5 [57]. في المرحلة السادسة، يكون أداء معظم مرضى السكتة الدماغية مشابهًا للأصحاء، مما يجعل من الصعب التمييز. بالإضافة إلى ذلك، قاموا بتصور حركات اليد للمساعدة في إعطاء نظرة ثاقبة للأطباء حول حركة المريض.

تستخدم معظم أنظمة التقييم الآلية العليا Kinect لجمع البيانات وFMA للتقييم، مع تمارين و/أو ميزات و/أو تصنيفات مختلفة.

الطرق [58-61]. يمكن أن يُعزى ذلك إلى سهولة إعداد Kinect، مع الاستمرار في أتمتة معظم FMA بدقة موثوقة. علاوة على ذلك، فمن خلال إضافة عدد قليل من أجهزة الاستشعار، من الممكن أتمتة FMA بالكامل. وعيب هذه الأنظمة هو الضوضاء التي يمكن أن تنتج في بيئات غير خاضعة للرقابة، مما يقلل من موثوقيتها.

ويمكن ملاحظة أنه على الرغم من وجود العديد من أنظمة التقييم الآلي للأطراف العلوية، إلا أن القليل منها قد طور إعادة تأهيل في المنزل تمت الموافقة عليها سريريًا. تم اختبار الأنظمة المقترحة في [16،62] فقط على الأشخاص الأصحاء. عادةً ما تقوم أنظمة مراقبة إنترنت الأشياء للأشخاص المسنين بمراقبة حركة المريض للتعرف على النشاط [15،63].

سلطت جائحة كوفيد-19 الضوء على الحاجة إلى أنظمة إعادة التأهيل داخل المنزل، خاصة مرافق رعاية كبار السن، حيث يمكن أن يؤدي تفشي المرض إلى معدل وفيات يزيد عن 25% [64]. يساهم العمل في هذه الورقة في إنشاء نظام تقييم آلي داخلي لإعادة تأهيل مرضى الأطراف العلوية الذين يتمتعون بدرجة عالية من الشفاء. يستخدم النظام إنترنت الأشياء للسماح بمراقبة تقدم المريض. يمكن إعداد هذا النظام غير المكلف بسهولة في المنزل ويستخدم فقط قفاز البيانات الموضح وتطبيق الهاتف المحمول، دون الحاجة إلى فني ماهر. تتطلب الأنظمة الأخرى المتوفرة حاليًا معدات باهظة الثمن، أو لا يمكن إعدادها بسهولة، أو لا تتواصل مع الطبيب المشرف. تعتبر عملية إعادة تأهيل إصابات ما بعد السكتة الدماغية مرهقة جسديًا وماليًا وعقليًا. وبدون الرعاية المناسبة، يجد المرضى صعوبة في التعامل مع إصاباتهم. من خلال التدريب، يمكن لأسرة المريض رعاية المريض مع القليل من المخاطر الإضافية، لأن هذا من شأنه أن يرفع من الصحة العقلية للمريض [49-51].

ولم يكن النظام الموضح خاليًا من القيود. وكانت قادرة فقط على تقييم أداء يد واحدة. في حين أنه من الممكن إضافة المزيد من التمارين والمعدات، فإن التكلفة ستزيد بشكل متناسب. بالإضافة إلى ذلك، ليس من السهل على مرضى السكتة الدماغية الذين يعانون من حركة يد محدودة ارتداء هذا القفاز، حتى مع المساعدة. يمكن أن تؤثر أحجام اليد المختلفة أيضًا على القراءات؛ ومن ثم، تم أخذ مجموعة البيانات واختبارها على أشخاص لديهم أحجام يد مماثلة. ومع ذلك، فإن هذه العيوب موجودة في جميع قفازات البيانات تقريبًا.

وسيركز العمل المستقبلي لهذا النظام على تطبيق المزيد من التصور ومراقبة الميزات الحركية من خلال الوصول إلى البيانات المخزنة في قاعدة البيانات. علاوة على ذلك، سيتم تنفيذ تصميم أكثر معيارية للقفازات للمساعدة في جمع البيانات وراحة المريض. وأخيرًا، سيتم استخدام المزيد من التمارين والميزات والمصنفات لتغطية المزيد من

تمارين FMA أو حتى طرق التقييم الأخرى التي يمكن أن تساعد في إعادة التأهيل المنزلي.

مساهمات المؤلف: التصور، S.A.M. و M.I.A. تنظيم البيانات، H.S. (حسين ثروت)، ث. و A.M.E.؛ التحليل الرسمي، ه.س. (حسين ثروت) وه.س. (حسن ثروت)؛ الحصول على التمويل، M.I.A.؛ التحقيق، ه.س. (حسن ثروت) وA.M.Eg. المنهجية، H.S. (حسين ثروت)، ث. و M.I.A. إدارة المشاريع، M.I.A.؛ الموارد، ه.س. (حسن ثروت)، A.M.E.، T.H.E. و M.I.A. البرمجيات، ه.س. (حسين ثروت)؛ الإشراف، S.A.M. و M.I.A. التحقق من الصحة، S.A.M. و M.I.A. الكتابة - المسودة الأصلية، ه.س. (حسين ثروت) وه.س. (حسن ثروت)؛ الكتابة – المراجعة والتحرير، S.A.M. و M.I. لقد قرأ جميع المؤلفين النسخة المنشورة من المخطوطة ووافقوا عليها.

التمويل: تم تمويل هذا المشروع، الذي يحمل عنوان iGrasp، من قبل هيئة تنمية صناعة تكنولوجيا المعلومات (ITIDA)، رقم المنحة CFP149.

بيان مجلس المراجعة المؤسسية: أجريت الدراسة وفقًا لإعلان هلسنكي، وتمت الموافقة على جميع الإجراءات التجريبية التي تم تنفيذها في هذا البحث من قبل مجلس المراجعة الأخلاقية بالجامعة.

بيان الموافقة المستنيرة: تم الحصول على موافقة مستنيرة من جميع الأشخاص المشاركين في الدراسة.

بيان توفر البيانات: البيانات التي تدعم نتائج هذه الدراسة متاحة بشكل مفتوح في مستودع عبر الإنترنت يسمى iGrasp_DataGlove على https://github.com/HSarwat/iGrasp_DataGlove (تم الوصول إليه في 16 سبتمبر 2021).

شكر وتقدير: نود أن نشكر هيئة تنمية صناعة تكنولوجيا المعلومات (إيتيدا) لتمويلها مشروع iGRASP ولمساهماتها السخية.

مراجع
References